



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Εργαστήριο Συστημάτων Τεχνητής Νοημοσύνης και Μάθησης

AI|LS

Παραγωγικά Μοντέλα και Εφαρμογές

Ηλίας Μήτσουρας

Διάρθρωση της Παρουσίασης

2

- ❑ **Εισαγωγή**
- ❑ Variational Autoencoders
- ❑ Generative Adversarial Networks
- ❑ Diffusion Models
- ❑ Εφαρμογές

Εισαγωγή

3


Παραγωγικά Μοντέλα (*Generative Models*)

- ▣ Οικογένεια στατιστικών μοντέλων
- ▣ Σκοπός τους είναι ο προσδιορισμός των υποκείμενων μοτίβων και κατανομών των διαθέσιμων δεδομένων
→ **παραγωγή νέων δειγμάτων**, τα οποία μοιράζονται παρόμοια χαρακτηριστικά με τα αρχικά δεδομένα.
- ▣ Πιο επίσημα, δοθέντος ενός συνόλου δεδομένων $X = \{x_1, x_2, \dots, x_n\}$, και ενός συνόλου ετικετών $Y = \{y_1, y_2, \dots, y_n\}$ (προαιρετικά), ένα παραγωγικό μοντέλο προσπαθεί να προσεγγίσει:
 - την από κοινού κατανομή $p(X, Y)$ ή
 - την κατανομή $p(X)$, σε περίπτωση όπου δεν δίνεται το σύνολο Y .
- ▣ Διαφέρουν από τα διακριτικά μοντέλα (*discriminative models*), τα οποία προσπαθούν να εκτιμήσουν την υπό συνθήκη κατανομή πιθανότητας $p(Y | X)$.
- ▣ Τα παραγωγικά μοντέλα ταξινομούνται βάσει του τρόπου με τον οποίο προσπαθούν να εκτιμήσουν τη συνάρτηση πυκνότητας πιθανότητας $p_{\text{model}}(X)$.

Εισαγωγή

4

Ταξινόμηση Παραγωγικών Μοντέλων



Διάρθρωση της Παρουσίασης

5

- Εισαγωγή
- ***Variational Autoencoders***
- Generative Adversarial Networks
- Diffusion Models
- Εφαρμογές

Variational Autoencoders

6

Μείωση Διαστάσεων (*Dimensionality Reduction*)


- ▣ Η μείωση Διαστάσεων αποσκοπεί στη **μείωση του πλήθους των χαρακτηριστικών** που χρησιμοποιούνται για να περιγράψουν τα δεδομένα.
- ▣ Είναι χρήσιμη σε διάφορες εφαρμογές οι οποίες απαιτούν δεδομένα χαμηλής διάστασης, όπως η οπτικοποίηση, η αποθήκευση κ.ά.
- ▣ Η μείωση της διάστασης των χαρακτηριστικών μπορεί να επιτευχθεί μέσω:
 - μεθόδων **επιλογής χαρακτηριστικών** (*feature selection*), στις οποίες επιλέγεται ένα υποσύνολο των αρχικών χαρακτηριστικών,
 - μεθόδων **εξαγωγής χαρακτηριστικών** (*feature extraction*), στις οποίες δημιουργείται ένα νέο σύνολο χαρακτηριστικών μικρότερου μεγέθους από το αρχικό, με τη μικρότερη δυνατή απώλεια πληροφορίας.

Variational Autoencoders

7

Autoencoders

- Νευρωνικό δίκτυο που μαθαίνει να μετασχηματίζει τα δεδομένα σε μία συμπιεσμένη μορφή και να ανακατασκευάζει τα αρχικά δεδομένα, με όσο το δυνατόν μικρότερες απώλειες.
- Ο *autoencoder* αποτελείται από δύο βασικά μέρη:
 - **Encoder:** χρησιμοποιείται για την παραγωγή μίας νέας, συμπιεσμένης αναπαράστασης των αρχικών δεδομένων.
 - **Decoder:** ανακατασκευάζει τα αρχικά δεδομένα βάσει της νέας συμπιεσμένης αναπαράστασης, με όσο το δυνατόν μικρότερες απώλειες.




Variational Autoencoders

8

Autoencoders – Αρχιτεκτονική και Εκπαίδευση

- Τα δίκτυα του encoder και του decoder υλοποιούνται μέσω νευρωνικών δικτύων, τα οποία επιλέγονται βάσει του τύπου των διαθέσιμων δεδομένων (εικόνες → συνελκτικά δίκτυα, διανύσματα → fully connected layers).
- Ο autoencoder εκπαιδεύεται μέσω μη επιβλεπόμενης μάθησης, καθώς έχουμε μη επισημασμένα δεδομένα.
- Σε κάθε επανάληψη:
 - Ο encoder κωδικοποιεί τα δεδομένα εισόδου $z = e_{\theta}(x)$.
 - Ο decoder ανακατασκευάζει τα αρχικά δεδομένα βάσει της κωδικοποίησης του encoder, $x' = d_{\varphi}(e_{\theta}(x))$.
 - Η ανακατασκευή x' συγκρίνεται με τα αρχικά δεδομένα x και βάσει της ομοιότητάς τους ανανεώνονται τα βάρη των δικτύων.




Loss Function: $\mathcal{L} = \|x - x'\|_2 = \|x - d_{\varphi}(e_{\theta}(x))\|_2$

Variational Autoencoders

9

Autoencoders και Παραγωγή νέων Δεδομένων

- ▣ Πώς συνδέεται ο autoencoder με την παραγωγή νέων δεδομένων;
- ▣ Θα μπορούσαμε να υποθέσουμε ότι, σε περίπτωση που ο latent χώρος είναι καλά δομημένος, τυχαία σημεία τα οποία δειγματοληπτούνται από αυτόν, μπορούν να αποκωδικοποιηθούν μέσω του decoder για την παραγωγή νέων συνθετικών δεδομένων.




Variational Autoencoders

10

Autoencoders και Παραγωγή νέων Δεδομένων

- Στην πράξη δεν μπορούμε να εγγυηθούμε εκ των προτέρων ότι ο encoder θα οργανώσει τον latent χώρο με τρόπο ώστε να μπορούμε να δειγματοληψήσουμε από αυτό και να παράγουμε νέα δείγματα.
- Ο υψηλός βαθμός ελευθερίας του autoencoder οδηγεί στην υπερπροσαρμογή, με αποτέλεσμα ο latent χώρος να είναι μη-κανονικοποιημένος (non-regularized).
- Αυτό έχει ως συνέπεια η αποκωδικοποίηση τυχαίων σημείων από τον latent χώρο να οδηγεί σε μη ρεαλιστικά ή χωρίς νόημα δεδομένα, τα οποία αποκλίνουν σημαντικά από τα πραγματικά δείγματα εκπαίδευσης.



Variational Autoencoders

11

Variational Autoencoders


- ▣ Προκειμένου να χρησιμοποιήσουμε τον decoder του autoencoder για την παραγωγή νέων συνθετικών δειγμάτων, θα πρέπει να εξασφαλίσουμε ότι ο latent χώρος είναι **κατάλληλα κανονικοποιημένος**.
- ▣ Για το σκοπό αυτό χρησιμοποιούνται οι **Variational Autoencoders**.
- ▣ **Variational Autoencoder**
 - Πρόκειται για έναν autoencoder με μηχανισμό κανονικοποίησης, ώστε να αποφευχθεί το φαινόμενο της υπερπροσαρμογής και να εξασφαλιστούν χρήσιμες ιδιότητες στον latent χώρο.
 - Παρόμοια με τον autoencoder, περιλαμβάνει έναν encoder και έναν decoder, οι οποίοι εκπαιδεύονται ώστε να ελαχιστοποιούν το σφάλμα ανακατασκευής μεταξύ των αρχικών δεδομένων και των encoded-decoded δεδομένων.
 - Η βασική διαφορά έγκειται στο ότι, αντί η είσοδος x να κωδικοποιείται ως ένα διάνυσμα, κωδικοποιείται πλέον ως **μία κατανομή $p(z | x)$ στον latent χώρο**.
 - Επομένως, ο encoder επιστρέφει δύο διανύσματα, ένα διάνυσμα μέσων τιμών μ και ένα διάνυσμα τυπικών αποκλίσεων σ .

Variational Autoencoders

12

Variational Autoencoders

- ▣ Προκειμένου ο Variational Autoencoder να μπορεί να παράγει νέα συνθετικά δεδομένα, θα πρέπει ο latent χώρος να είναι:
 - **Συνεχής (Continuous):** Παρόμοιες είσοδοι θα πρέπει να έχουν παρόμοιες λανθάνουσες αναπαραστάσεις, διασφαλίζοντας ομαλές μεταβάσεις στον latent χώρο.
 - **Πλήρης (Complete):** Το μοντέλο θα πρέπει να αξιοποιεί αποδοτικά ολόκληρο τον latent χώρο.




Variational Autoencoders


13

Variational Autoencoders

- Η τροποποίηση του encoder του VAE ώστε να μοντελοποιεί κατανομές πιθανότητες αντί για σημεία, δεν εγγυάται τις δύο ανωτέρω προδιαγραφές, καθώς αυτός μπορεί:
 - Να οδηγεί σε **πολύ μικρές διασπορές** στις λανθάνουσες αναπαραστάσεις, με αποτέλεσμα να συμπεριφέρονται σαν σταθερά σημεία.
 - Να **απομακρύνει αρκετά τις μέσες τιμές** των κατανομών, οδηγώντας σε κενά και ασυνέχεια στον latent χώρο.
- Για να αποφύγουμε τα προβλήματα αυτά:
 - **Κανονικοποίηση μέσης τιμής και τη διασποράς** των κατανομών των λανθανουσών αναπαραστάσεων
→ **Κανονική κατανομή**.



Τι μπορεί να συμβεί χωρίς κανονικοποίηση ❌




✓ Τι θέλουμε να επιτύχουμε μέσω κανονικοποίησης

Variational Autoencoders

14

Variational Autoencoders




$$\text{Loss Function: } \mathcal{L} = \left\| x' - d_\phi(e_\theta(x)) \right\|_2 + D_{KL}(\mathcal{N}(\mu_x, \sigma_x) \parallel \mathcal{N}(\mathbf{0}, I))$$

Variational Autoencoders

15

Variational Autoencoders – Σύνθεση Νέων Δειγμάτων

- Μπορούμε να χρησιμοποιήσουμε μόνο τον Decoder ενός VAE για να παράξουμε νέα δείγματα.
- Διαδικασία**
 - Δειγματοληψία στον latent χώρο, θεωρώντας μια κανονική κατανομή, $z \sim \mathcal{N}(\mathbf{0}, I)$.
 - Αποκωδικοποίηση της λανθάνουσας αναπαράστασης z μέσω του Decoder και παραγωγή νέου δείγματος $x' = d_\phi(z)$.



Variational Autoencoders

16



Δείγματα από VAE.

Διάρθρωση της Παρουσίασης

17

- Εισαγωγή
- Variational Autoencoders
- ***Generative Adversarial Networks***
- Diffusion Models
- Εφαρμογές

Generative Adversarial Networks

18

Generative Adversarial Networks (GANs)

- ▣ Πρωτοπαρουσιάστηκαν από τον Ian Goodfellow και τους συνεργάτες του το 2014.
- ▣ **Σκοπός:** η παραγωγή νέων δειγμάτων παρόμοιων με τα αρχικά διαθέσιμα δεδομένα.
- ▣ Η **αρχιτεκτονική** των GANs αποτελείται από 2 νευρωνικά δίκτυα που ανταγωνίζονται μεταξύ τους:
 - **Generator**
Δημιουργεί **νέα συνθετικά δεδομένα** από **τυχαίο θόρυβο**, με στόχο να είναι όσο το δυνατόν πιο ρεαλιστικά, ούτως ώστε ο Discriminator να μην μπορεί να τα διακρίνει από τα αρχικά δεδομένα.
 - **Discriminator**
Λειτουργεί ως **κριτής**, προσπαθώντας να διακρίνει εάν τα δεδομένα τα οποία δέχεται ως είσοδο είναι πραγματικά (real) ή ψεύτικα (fake).
- ▣ Τα δύο δίκτυα ανταγωνίζονται συνεχώς, με τρόπο ώστε:
 - Ο Generator να βελτιώνεται στην παραγωγή ρεαλιστικών συνθετικών δειγμάτων και
 - Ο Discriminator να βελτιώνεται στην ανίχνευση των ψεύτικων δειγμάτων.

Generative Adversarial Networks

19

Αρχιτεκτονική GANs

□ Generator

- Πρόκειται για βαθύ νευρωνικό δίκτυο, το οποίο λαμβάνει ως είσοδο τυχαίο θόρυβο (latent χώρος) και παράγει ρεαλιστικά δεδομένα, παρόμοια με τα αρχικά (π.χ. εικόνες).
- Μαθαίνει την υποκείμενη κατανομή των δεδομένων.


□ Discriminator

- Νευρωνικό δίκτυο το οποίο χρησιμοποιείται για τη δυαδική ταξινόμηση των δεδομένων τα οποία λαμβάνει στην είσοδό του (αληθινά ή ψεύτικα).
- Λαμβάνει δεδομένα από δύο πηγές:
 - **Αληθινά δεδομένα** από το σύνολο των διαθέσιμων δεδομένων, τα οποία χρησιμοποιούνται ως **positive examples** κατά την εκπαίδευση.
 - **Συνθετικά δεδομένα** από τον Generator, τα οποία χρησιμοποιούνται ως **negative examples** κατά την εκπαίδευση.
- Βελτιώνει την ικανότητά του να διακρίνει αληθινά και ψεύτικα δεδομένα μέσω εκπαίδευσης.
- Η αρχιτεκτονική του εξαρτάται από τον τύπο των δεδομένων εισόδου (εικόνες → συνελκτικά δίκτυα).

Generative Adversarial Networks

20

Αρχιτεκτονική GANs




Generative Adversarial Networks

21

Εκπαίδευση GANs

- Η εκπαίδευση των δικτύων πραγματοποιείται με **μη επιβλεπόμενο** (unsupervised) και **ανταγωνιστικό** (adversarial) τρόπο.
- Στην αρχή της εκπαίδευσης, ο Generator παράγει ψεύτικα δεδομένα, τα οποία ο Discriminator εύκολα διακρίνει ως ψεύτικα.
- Όσο η εκπαίδευση συνεχίζει, ο Generator παράγει δεδομένα όλο και πιο όμοια με τα αρχικά, με αποτέλεσμα να δυσκολεύει τον Discriminator.
- Τελικά, καθώς η ικανότητα του Generator να παράγει αληθοφανή δεδομένα βελτιώνεται, η ικανότητα του Discriminator να ταξινομεί τα δεδομένα ως αληθινά ή ψεύτικα μειώνεται.



Generative Adversarial Networks

22

Εκπαίδευση GANs

- ▣ Η βασική ιδέα κατά την εκπαίδευση των GANs είναι:
 - Εάν ο Discriminator ταξινομεί ορθά τα δεδομένα που λαμβάνει στην είσοδό του ως αληθινά ή ψεύτικα, ενισχύει την ικανότητά του.
 - Εάν ο Generator ξεγελά επιτυχημένα τον Discriminator μέσω των δεδομένων που παράγει, λαμβάνει κάποιο reward, ενώ ο Discriminator κάποιο penalty.
- ▣ Τα δίκτυα του Generator και του Discriminator εκπαιδεύονται σε **ξεχωριστές εναλλασσόμενες** περιόδους. Πιο συγκεκριμένα:
 1. Ο Discriminator εκπαιδεύεται για κάποιο αριθμό βημάτων.
 2. Έπειτα εκπαιδεύεται ο Generator.
 3. Τα βήματα 1. και 2. επαναλαμβάνονται μέχρι τη σύγκλιση.
- ▣ Κατά την εκπαίδευση του Discriminator (Βήμα 1.) ο Generator παραμένει σταθερός (frozen).
- ▣ Κατά την εκπαίδευση του Generator (Βήμα 2.) ο Discriminator παραμένει σταθερός (frozen).

Generative Adversarial Networks

23

Εκπαίδευση GANs – Εκπαίδευση Discriminator

1. Δειγματοληψία ενός συνόλου **αληθινών δεδομένων** από το σύνολο των δεδομένων εκπαίδευσης.
2. Δημιουργία ενός συνόλου **ψεύτικων δεδομένων** μέσω του Generator.
3. Τροφοδότηση **αληθινών και ψεύτικων** δεδομένων στον Discriminator.
4. Δυαδική ταξινόμηση των δεδομένων σε αληθινά ή ψεύτικα.
5. Ανανέωση των βαρών του Discriminator, ώστε να **μεγιστοποιηθεί** η συνάρτηση,

$$\mathcal{L}_D = \mathbb{E}_{\mathbf{x} \sim p_{data}} [\log \mathbf{D}(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z} \left[\log \left(1 - \mathbf{D}(\mathbf{G}(\mathbf{z})) \right) \right].$$


Στην ανωτέρω συνάρτηση:

- $\mathbf{D}(\mathbf{x})$ η πιθανότητα το δεδομένο $\mathbf{x}$ να είναι αληθινό, όπως αυτή εκτιμάται από τον Discriminator.
- $\mathbf{G}(\mathbf{z})$ η έξοδος του Generator, δοθέντος τυχαίου θορύβου $\mathbf{z}$.
- $\mathbf{D}(\mathbf{G}(\mathbf{z}))$ η πιθανότητα το ψεύτικο δείγμα $\mathbf{G}(\mathbf{z})$ να είναι αληθινό, όπως αυτή εκτιμάται από τον Discriminator.
- Ο τύπος προκύπτει από την εφαρμογή της binary cross-entropy loss αθροιστικά για τα αληθινά και τα συνθετικά δεδομένα: $\mathcal{L}_D = \text{BCE}(1, \mathbf{D}(\mathbf{x})) + \text{BCE}(0, \mathbf{D}(\mathbf{G}(\mathbf{z})))$.

Generative Adversarial Networks

24

Εκπαίδευση GANs – Εκπαίδευση Discriminator



Generative Adversarial Networks

25

Εκπαίδευση GANs – Εκπαίδευση Generator

1. Δημιουργία ενός συνόλου **ψεύτικων δεδομένων** μέσω του Generator.
2. Τροφοδότηση **μόνο ψεύτικων** δεδομένων στον Discriminator.
3. Δυναμική ταξινόμηση των δεδομένων σε αληθινά ή ψεύτικα.
4. Ανανέωση των βαρών του Generator, ώστε να **ελαχιστοποιηθεί** η συνάρτηση,

$$\mathcal{L}_G = \mathbb{E}_{z \sim p_z} \left[\log \left(1 - D(G(z)) \right) \right].$$


Στην ανωτέρω συνάρτηση:

- $G(z)$ η έξοδος του Generator, δοθέντος τυχαίου θορύβου z .
- $D(G(z))$ η πιθανότητα το ψεύτικο δείγμα $G(z)$ να είναι αληθινό, όπως αυτή εκτιμάται από τον Discriminator.

Generative Adversarial Networks

26

Εκπαίδευση GANs – Εκπαίδευση Generator



Generative Adversarial Networks

27

Εκπαίδευση GANs – Προβλήματα Σύγκλισης

- ▣ **Vanishing (ή Exploding) Gradients**
 - Σε περίπτωση που ο Discriminator είναι «πολύ καλός» κριτής, η πιθανότητα $D(G(z)) \rightarrow 0$ για κάθε z και έτσι η παράγωγος $\nabla \log(1 - D(G(z)))$ «εξαφανίζεται», με αποτέλεσμα ο Generator να σταματάει να μαθαίνει.
 - Αντίστοιχα, σε περίπτωση που ο Discriminator είναι «πολύ αδύναμος» κριτής παρουσιάζεται το φαινόμενο του exploding gradient.
- ▣ **Ταλαντώσεις και Αδυναμία Σύγκλισης**
 - Εμφάνιση ταλαντώσεων στις εξόδους και στις τιμές της συνάρτησης απώλειας.
 - **Αιτία:** ανισορροπία στις ανανεώσεις των βαρών των δικτύων του Generator και του Discriminator και έλλειψη θεωρητικού υποβάθρου το οποίο να εξασφαλίζει τη σύγκλιση.

Generative Adversarial Networks

28

Εκπαίδευση GANs – Προβλήματα Σύγκλισης

- ▣ **Mode Collapse**
 - Φαινόμενο κατά το οποίο ο Generator παράγει δείγματα περιορισμένων μοτίβων και ποικιλίας.
 - **Αιτία:** ο Generator συγκλίνει κατά την εκπαίδευση σε ένα περιορισμένο σύνολο δεδομένων, το οποίο ξεγελά σταθερά τον Discriminator και προσκολλάται σε αυτό (zero gradients).

Εκπαίδευση GANs – Minimax game

- ▣ Πρακτικά, η εκπαίδευση των GANs προσομοιάζει ένα **παίγνιο μηδενικού και σταθερού αθροίσματος** (two-player zero-sum game), στο οποίο το κέρδος του ενός παίκτη (Generator) ισούται με τη ζημιά του άλλου (Discriminator).
- ▣ Ακολουθείται η στρατηγική **Minimax** για την εκπαίδευση των μοντέλων, βάσει της συνολικής αντικειμενικής συνάρτησης:

$$\min_G \max_D \mathbb{E}_{\mathbf{x} \sim p_{data}} [\log \mathbf{D}(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z} \left[\log \left(1 - \mathbf{D}(\mathbf{G}(\mathbf{z})) \right) \right].$$

Generative Adversarial Networks

29



Δείγματα από GAN.

Διάρθρωση της Παρουσίασης

30

- Εισαγωγή
- Variational Autoencoders
- Generative Adversarial Networks
- ***Diffusion Models***
- Εφαρμογές

Diffusion Models

31

Diffusion Models

- ❑ Τα μοντέλα διάχυσης πρωτοπαρουσιάστηκαν το 2015.
- ❑ Αποτελούν μία κλάση στατιστικών παραγωγικών μοντέλων.
- ❑ Εμπνέονται από τις αρχές της θερμοδυναμικής (non-equilibrium thermodynamics).
- ❑ **Λειτουργία:** διαδοχική έγχυση θορύβου στα διαθέσιμα δεδομένα (forward diffusion) και προσπάθεια εκμάθησης της αντίστροφης διαδικασίας αποθορυβοποίησης (reverse diffusion).




Diffusion Models

32

Διαδικασία Διάχυσης (Forward Diffusion)

- Διαδοχική προσθήκη θορύβου στα αρχικά δεδομένα μέχρι να καταστραφεί πλήρως η δομή τους $\rightarrow$ θόρυβος.
 - Η forward diffusion μοντελοποιείται μέσω μιας Μαρκοβιανής αλυσίδας.
 - Δοθέντος ενός δείγματος x_0 από μια κατανομή $x_0 \sim q_0(x)$, κατά το forward diffusion προσθέτουμε διαδοχικά Γκαουσιανό θόρυβο στο δείγμα σε T βήματα, παράγοντας μια ακολουθία ενθόρυβων δειγμάτων $x_1, x_2, \dots, x_T$.
 - Χρησιμοποιείται ο πυρήνας μετάβασης $q(x_t | x_{t-1})$, ο οποίος ισούται με:
- Στην παραπάνω σχέση, το μέγεθος του βήματος ελέγχεται από μία παράμετρος, η οποία καλείται variance schedule $\{\beta_t \in (0,1)\}_{t=1}^T$.




Diffusion Models

33

Διαδικασία Αντίστροφης Διάχυσης (Reverse Diffusion)

- Αν αντιστρέψουμε τη διαδικασία του forward diffusion και να κάνουμε δειγματοληψία από την κατανομή $q(x_{t-1} | x_t)$, μπορούμε να συνθέσουμε νέα δείγματα, ξεκινώντας από Γκαουσιανό θόρυβο $x_T \sim \mathcal{N}(0, I)$.



- **Το πρόβλημα:** η κατανομή $q(x_{t-1} | x_t)$ δεν μπορεί **εκτιμηθεί** (intractable), γιατί απαιτεί υπολογισμούς με όλα τα διαθέσιμα δεδομένα.
- **Η λύση:** χρήση νευρωνικού δικτύου $p_\theta(x_{t-1} | x_t)$ για την προσέγγιση των υπό συνθήκη κατανομών $q(x_{t-1} | x_t)$.

Diffusion Models

34

Δίκτυο Αποθορυβοποίησης

- Το ενθόρυβο δείγμα x_t στο βήμα t του forward diffusion προκύπτει από το reparametrization trick, ως εξής:


- όπου, $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ και $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ τυχαίος θόρυβος.
$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t,$$
- Αποδεικνύεται ότι, αρκεί να εκπαιδεύσουμε ένα νευρωνικό δίκτυο αποθορυβοποίησης $\epsilon_\theta(x_t, t)$, ώστε να υπολογίζει το θόρυβο ϵ_t στο τυχόν βήμα t και στη συνέχεια να το χρησιμοποιήσουμε για την παραγωγή νέων δειγμάτων.
- Διαδικασία εκπαίδευσης**
 - Δοθέντος ενός αρχικού δείγματος $x_0 \sim q_0(x)$, επιλέγουμε τυχαία ένα επίπεδο θορύβου $t \sim \text{Uniform}(\{1, \dots, T\})$.
 - Παράγουμε θόρυβο $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
 - Δημιουργούμε την ενθόρυβη εκδοχή του δείγματος x_t .
 - Λαμβάνουμε την εκτίμηση του θορύβου $\epsilon_\theta(x_t, t)$, μέσω του δικτύου αποθορυβοποίησης.
 - Ανανεώνουμε τα βάρη, ώστε να ελαχιστοποιείται η διαφορά $\|\epsilon_t - \epsilon_\theta(x_t, t)\|^2$.

Diffusion Models

35

Δίκτυο Αποθουροποίησης


- ▣ Διαδικασία εκπαίδευσης



Diffusion Models


36

- ▣ **Αρχιτεκτονική**
 - Η πιο συνηθισμένη αρχιτεκτονική του δικτύου αποθουροποίησης είναι αυτή του δικτύου U-Net, η οποία περιλαμβάνει εκτός από συνελκτικά layers και attention layers.
 - Οι πιο καινούριες αρχιτεκτονικές βασίζονται εξ ολοκλήρου σε δομές transformers, οι οποίες είναι ειδικά σχεδιασμένες για τις ανάγκες των diffusion μοντέλων (Diffusion transformers).
- ▣ **Σύνθεση νέων δειγμάτων**
 - Αξιοποιώντας το εκπαιδευμένο δίκτυο αποθουροποίησης, μπορούμε να ακολουθήσουμε τη reverse diffusion διαδικασία βήμα προς βήμα και να παράξουμε νέα δεδομένα.



Diffusion Models

37



Διαδικασία reverse diffusion – Παραγωγή νέου δείγματος.

Diffusion Models

38

Denoising Diffusion Implicit Models

- Στα παραδοσιακά μοντέλα διάχυσης (DDPMs) η διαδικασία του forward diffusion μπορεί να περιλαμβάνει αρκετές χιλιάδες βήματα.
- Για να παράξουμε νέα δείγματα, θα πρέπει να ακολουθήσουμε αντίστροφα όλα τα βήματα αυτά → υψηλοί χρόνοι εκτέλεσης.
- **Λύση:** τα Denoising Diffusion Implicit Models, τα οποία επεκτείνουν την ιδέα των παραδοσιακών μοντέλων διάχυσης σε μη-Μαρκοβιανές περιπτώσεις.


Εκπαίδευση	Δειγματοληψία
Μεγάλος αριθμός χρονικών βημάτων T (συνήθως μερικές χιλιάδες)	Υποσύνολο των βημάτων που χρησιμοποιούνται κατά την εκπαίδευση

Diffusion Models

39

Score-Based Generative Models

- Το δεύτερο μέλος της οικογένειας των μοντέλων διάχυσης.
- Η βασική ιδέα των μοντέλων αυτών είναι η χρήση ενός νευρωνικού δικτύου s_θ για την εκτίμηση της **score function** και η δημιουργία νέων δειγμάτων με χρήση score-based μεθόδων δειγματοληψίας.
- Η score function μιας πυκνότητας πιθανότητας $p(\mathbf{x})$ ορίζεται ως $\nabla_{\mathbf{x}} \log p(\mathbf{x})$.
- Πρόκειται ουσιαστικά για ένα διανυσματικό πεδίο, το οποίο δείχνει προς την κατεύθυνση εκείνη στην οποία μεγιστοποιείται η λογαριθμική πυκνότητα των δεδομένων.
- Το νευρωνικό δίκτυο εκπαιδεύεται ώστε να προσεγγίζει την ποσότητα αυτή, δηλαδή $s_\theta \approx \nabla_{\mathbf{x}} \log p(\mathbf{x})$.



Diffusion Models

40

Score-Based Generative Models – Δειγματοληψία με Langevin Dynamics

- ▣ Αφού έχουμε εκπαιδεύσει το δίκτυο s_θ μπορούμε να παράξουμε νέα δείγματα χρησιμοποιώντας μια Markov Chain Monte Carlo μέθοδο δειγματοληψίας, τα **Langevin Dynamics**.
- ▣ Η μέθοδος αυτή, επιτρέπει τη λήψη δειγμάτων από μία κατανομή $p(x)$, χρησιμοποιώντας αποκλειστικά τη score function $\nabla_x \log p(x)$.
- ▣ Πιο συγκεκριμένα, ξεκινώντας από ένα δείγμα $x_0 \sim \pi(x)$, όπου $\pi(x)$ μια prior κατανομή και με βήμα $\epsilon > 0$, η μέθοδος των Langevin Dynamics υπολογίζει αναδρομικά, για T βήματα, το ακόλουθο:

όπου $z_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

- ▣ Όταν $\epsilon \rightarrow 0$ και $T \rightarrow \infty$, η κατανομή των δειγμάτων $\tilde{x}_T$ προσεγγίζει την κατανομή $p(x)$.
- ▣ Στην πράξη, επιλέγουμε ένα αρκετά μικρό ϵ και ένα αρκετά μεγάλο T .


$$x_t = x_{t-1} + \frac{\epsilon}{2} \nabla_x \log p(x_{t-1}) + \sqrt{\epsilon} z_t$$

Diffusion Models

41

Stochastic Differential Equations

- Τόσο τα παραδοσιακά μοντέλα διάχυσης, όσο και τα Score-based Generative μοντέλα, μπορούν να θεωρηθούν ως διακριτοποιήσεις στοχαστικών διαφορικών εξισώσεων.
- Στις έως τώρα προσεγγίσεις, χρησιμοποιείται ένα πεπερασμένο πλήθος επιπέδων θορύβου.
- Μπορούμε να επεκτείνουμε τη λογική αυτή και να χρησιμοποιήσουμε ένα συνεχές φάσμα κατανομών θορύβου για να προσθέσουμε θόρυβο στα δεδομένα.
- Οι κατανομές των ενθόρυβων δεδομένων, εξελίσσονται χρονικά σύμφωνα με μία Στοχαστική Διαφορική Εξίσωση:



Diffusion Models

42

Stochastic Differential Equations

- ▣ Παρατηρούμε ότι υπάρχουν αρκετές αναλογίες μεταξύ των παραδοσιακών μοντέλων διάχυσης, των Score-based Generative μοντέλων και των SDEs.
 - Τα διακριτά βήματα $t = 1, 2, \dots, T$, γενικεύονται σε βήματα στο συνεχές φάσμα $t \in [0, T]$.
 - Τα διακριτά επίπεδα θορύβου που ελέγχονται μέσω της παραμέτρου β_t , αντιστοιχούν στο συντελεστή διάχυσης $g(t)$ της SDE.
- ▣ Προκειμένου τώρα να παράξουμε νέα δείγματα $x(0) \sim p_0$, μπορούμε, ξεκινώντας από ένα δείγμα $x(T) \sim p_T$ να ακολουθήσουμε την αντίστροφη SDE,
- ▣ Για να κάνουμε δειγματοληψία από την κατανομή p_0 , θα πρέπει να προσομοιώσουμε την αντίστροφη SDE, η οποία προϋποθέτει την εκτίμηση της score function $\nabla_x \log_t p(x)$.
- ▣ Η score function αυτή είναι προφανώς η ίδια με αυτή της περίπτωσης των Score-based Generative Μοντέλων.

$$dx = [f(x, t) - g(t)^2 \nabla_x \log_t p(x)]dt + g(t)d\bar{w}.$$

Diffusion Models

43

Περιορισμοί

- Υψηλό Υπολογιστικό Κόστος
 - Ανάγκη για πληθώρα υπολογιστικών πόρων → δύσκολη υλοποίηση σε πραγματικό χρόνο
 - Αργή και ιδιαίτερα απαιτητική σε hardware εκπαίδευση
- Δυσκολία Γενίκευσης σε Άγνωστα Δεδομένα
 - Ανάγκη επανεκπαίδευσης και προσαρμογής
- Υψηλό Επίπεδο Πολυπλοκότητας
 - Αδυναμία ενσωμάτωσης και χρήσης σε εφαρμογές οι οποίες απαιτούν γνώση του ακριβούς τρόπου λειτουργίας τους.
- Ελλιπής ικανότητα ερμηνείας των αποτελεσμάτων
 - Προκλήσεις σε εφαρμογές ερμηνεύσιμης τεχνητής νοημοσύνης (Explainable AI)
- Πολωμένα Αποτελέσματα
 - Οι παραγόμενες εικόνες μπορεί να παρουσιάζουν απόκλιση από τις κειμενικές περιγραφές, λόγω έλλειψης ισορροπίας στα δεδομένα εκπαίδευσης.

"A group of watches showing 5 minutes past 12"



Παραγωγή με χρήση του Stable Diffusion

"A left-handed person writing down on a notebook"




Παραγωγή με χρήση του Stable Diffusion

Diffusion Models

44

Generative Models Trilemma

- Βασικοί στόχοι ενός παραγωγικού μοντέλου:
 - 1) Παραγωγή υψηλής ποιότητας δειγμάτων,
 - 2) Παραγωγή diverse δειγμάτων και
 - 3) Γρήγορη παραγωγή δειγμάτων με χαμηλό υπολογιστικό κόστος.
- Δεν υπάρχει κάποιο παραγωγικό framework που να ικανοποιεί και τα 3 κριτήρια.
- Variational Autoencoders (VAEs) → χαμηλή ποιότητα παραγόμενων δειγμάτων.
- Generative Adversarial Networks (GANs) → περιορισμένη ποικιλία στα παραγόμενα δείγματα.
- Diffusion Models → υψηλό υπολογιστικό κόστος (μεγάλος αριθμός βημάτων για παραγωγή νέων δειγμάτων).



Διάρθρωση της Παρουσίασης

45

- Εισαγωγή
- Variational Autoencoders
- Generative Adversarial Networks
- Diffusion Models
- **Εφαρμογές**

Εφαρμογές

46

Text-to-Image Synthesis

- ▣ Τα μοντέλα διάχυσης μπορούν να χρησιμοποιηθούν για την **παραγωγή εικόνων** από κειμενικές περιγραφές.
- ▣ **Γνωστά μοντέλα:**
 - *DALL-E 2, DALL-E 3*
 - *Stable Diffusion*
 - *MidJourney*
 - *Imagen*



"a hedgehog using a calculator"



"a corgi wearing a red bowtie and a purple party hat"



"robots meditating in a vipassana retreat"




"a fall landscape with a small cottage next to a lake"

Εφαρμογές

47

Text-to-Image Synthesis – Stable Diffusion

- Χρησιμοποιεί ένα δίκτυο αποθρομβοποίησης τύπου U-Net.
- Κάθε block του U-Net αποτελείται από συνελικτικά layers ακολουθούμενα από self-attention και cross-attention layers.
- Η κειμενική καθοδήγηση εισέρχεται στη διαδικασία της διάχυσης μέσω των cross-attention layers.




Εφαρμογές

48

Image Editing

- Τα μοντέλα διάχυσης μπορούν να χρησιμοποιηθούν για την **επεξεργασία εικόνων**, διατηρώντας το φωτορεαλισμό και την ευκρίνειά τους.
 - Αλλαγή εκφράσεων προσώπου
 - Προσθήκη/αφαίρεση αντικειμένων
 - Αλλαγή χρωμάτων κ.ά.
- Γνωστά μοντέλα:**
 - DreamBooth*
 - Stable Diffusion (+ ControlNet)*
 - Instruct Pix2Pix*



Εφαρμογές

49

Image Super-Resolution

- Στο task του Image Super-Resolution θέλουμε να αυξήσουμε την ανάλυση μιας εικόνας χαμηλής ανάλυσης.
- Ιδιαίτερα χρήσιμο για τη βελτίωση της ανάλυσης παλιών φωτογραφιών και φωτογραφιών από πλάνα ασφαλείας.
- Οι Ho et al. 2022 πρότειναν μια αρχιτεκτονική πολλαπλών σταδίων, στην οποία μια σειρά από μοντέλα διάχυσης χρησιμοποιούνται για να αυξήσουν διαδοχικά την ανάλυση των εικόνων.
- Ξεκινώντας με ένα βασικό μοντέλο, το οποίο παράγει μια εικόνα σε χαμηλή ανάλυση, ακολουθούν upsampling μοντέλα, τα οποία αυξάνουν προοδευτικά την ανάλυση και το επίπεδο των λεπτομερειών.




Image-to-Image Translation

- ▣ Σκοπός του Image-to-Image Translation είναι η μεταφορά εικόνων από ένα αρχικό πεδίο (source domain) σε ένα άλλο (target domain), διατηρώντας την αναπαράσταση του αρχικού περιεχομένου.
- ▣ Πληθώρα εφαρμογών
- ▣ **Depth-to-Image Generation**
 - Μετατροπή χάρτη βάθους (depth map) σε εικόνα.
 - Χάρτης βάθους → Εικόνα σε γκριζα κλίμακα. Τα μαύρα αναπαριστούν περιοχές μεγάλου και τα άσπρα περιοχές χαμηλού βάθους.

Source Domain



Target Domain




Εφαρμογές

51



Image-to-Image Translation

- ▣ **Pose-to-Image Generation**
 - Μετατροπή εικόνας σκελετού (skeleton image) σε εικόνα.
- ▣ **Sketch-to-Image Generation**
 - Μετατροπή εικόνας σκίτσου (sketch image) σε εικόνα.
- ▣ **Semantic Segmentation-to-Image Generation**
 - Παραγωγή εικόνων από χάρτες σημασιολογικής κατάτμησης (segmentation maps).

Source Domain



Target Domain




Εφαρμογές

52

Image-to-Image Translation - ControlNet

- Adapter-like δίκτυο, το οποίο λειτουργεί παράλληλα με τη βασική αρχιτεκτονική του Stable Diffusion.
- Επιτρέπει την καθοδήγηση της σύνθεσης βάσει εξωτερικών συνθηκών.
- Κατά την εκπαίδευση το Stable Diffusion παραμένει frozen και ανανεώνονται μόνο τα βάρη του ControlNet.






Εφαρμογές

53

3D Content Generation

Text-to-3D




Poole, B., Jain, A., Barron, J. T., & Mildenhall, B. (2022). *DreamFusion: Text-to-3D using 2D Diffusion*.

Huang, Z., Guo, Y.-C., An, X., Yang, Y., Li, Y., Zou, Z.-X., Liang, D., Liu, X., Cao, Y.-P., & Sheng, L. (2024). *MIDI: Multi-Instance Diffusion for Single Image to 3D Scene Generation*.

Εφαρμογές

54

3D Content Generation



Εφαρμογές

55

Text or Image-to-Video Generation

- ▣ Τα μοντέλα διάχυσης μπορούν να χρησιμοποιηθούν για την παραγωγή βίντεο από κειμενικές περιγραφές ή εικόνες.
- ▣ **Γνωστά μοντέλα:**
 - *Stable Video Diffusion*
 - *Sora*
 - *ModelScopeT2V*
 - *CogVideoX*

Source Image



Generated Video



Παραγωγή με χρήση του *Stable Video Diffusion*.

Text Prompt

“Confident teddy bear surfer rides the wave in the tropics”

Generated Video




Παραγωγή με χρήση του *ModelScopeT2V*.

Εφαρμογές

56

Floorplan Synthesis

- ▣ Δημιουργία κατόψεων εσωτερικού χώρου.
- ▣ Η διασύνδεση των χώρων αναπαρίσταται μέσω γράφων.
- ▣ Ικανότητα ορισμού γωνιών ανά χώρο.



Εφαρμογές

57

Biomedical Domain

- ▣ Τα παραγωγικά μοντέλα έχουν παρουσιάζουν σημαντική επίδραση στον τομέα της ιατρικής απεικόνισης (medical imaging), παρέχοντας εργαλεία που διευκολύνουν το έργο των ιατρών και των ασθενών.
- ▣ Η διαδικασία συλλογής απεικονιστικών δεδομένων είναι συχνά πολύπλοκη και χρονοβόρα.
 - Εξειδικευμένα πρωτόκολλα και περιορισμοί.
 - Έλλειψη εξειδικευμένων επαγγελματιών για την επισήμανση (annotation) των δεδομένων.
 - Ζητήματα ιδιωτικότητας και ανάγκη για ρητή συναίνεση των ασθενών για διάθεση των προσωπικών τους δεδομένων.
 - Έντονη ανισορροπία στις κλάσεις των δεδομένων, λόγω της φύσης ορισμένων παθολογιών.
- ▣ Τα παραγωγικά μοντέλα προσφέρουν λύσεις στα προβλήματα αυτά καθώς:
 - Δημιουργούν ρεαλιστικά συνθετικά δεδομένα ιατρικών απεικονίσεων.
 - Αίρουν το ζήτημα της προστασίας της ιδιωτικότητας, μέσω δεδομένων που δεν βασίζονται σε πραγματικούς ασθενείς.


Εφαρμογές

58

Biomedical Domain

■ Synthetic Data Generation

- Έχει αποδειχθεί (Chen et al., 2021) ότι η συνδυαστική χρήση **συνθετικών και πραγματικών δεδομένων** για την εκπαίδευση ταξινομητών σε εικόνες ιστολογίας, **βελτιώνει την απόδοση**.
- Μελέτη η οποία διεξήχθη για την αξιολόγηση των μορφολογικών χαρακτηριστικών συνθετικών και πραγματικών εικόνων σε παθολόγους διαφόρων επιπέδων εμπειρίας (Moghadam et al., 2023), έδειξε ότι οι παθολόγοι δεν μπορούσαν να διακρίνουν τις συνθετικές εικόνες από τις πραγματικές.




Συνθετικές ιστοπαθολογικές εικόνες που δημιουργήθηκαν από το μοντέλο MFDPM (Moghadam et al., 2023).

Biomedical Domain

Image-to-Image Translation

- Οι πολυτροπικές (multi-modality) ιατρικές εικόνες είναι καθοριστικές για τη διάγνωση και τη θεραπεία.
- Σε αρκετές περιπτώσεις, λείπει κάποια απεικονιστική ακολουθία.
- Τα παραγωγικά μοντέλα έχουν παρουσιάσει ενθαρρυντικά αποτελέσματα στην παραγωγή των απουσιάζουσών απεικονιστικών modalities, π.χ. μετατροπή από *MRI* σε Αξονική Τομογραφία (*CT*).



Διαφορετικές μέθοδοι για translation από MRI εικόνες σε CT Scans (Lyu and Wang, 2022).


Εφαρμογές

60

Biomedical Domain

Image Denoising

- Στην ιατρική απεικόνιση είναι συχνό το φαινόμενο κάποιες εικόνες να επηρεάζονται από θόρυβο κατά τη διάρκεια της απόκτησής τους ή των περαιτέρω σταδίων επεξεργασίας
- Λόγω τη φύσης τους τα μοντέλα διάχυσης μπορούν να χρησιμοποιηθούν για αποθορυβοποίηση.
- Οι Hu et al. (2022) χρησιμοποίησαν ένα DDPM για την αποθορυβοποίηση εικόνων του αμφιβληστροειδούς χιτώνα (retina) του ματιού



Αποτελέσματα αποθορυβοποίησης για διάφορα επίπεδα SNR και για διαφορετικές τιμές t . Το καλύτερο για κάθε επίπεδο SNR επισημαίνεται με κόκκινο πλαίσιο (Hu et al., 2022).



Παραγωγή με χρήση του Stable Diffusion