



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Εργαστήριο Συστημάτων Τεχνητής Νοημοσύνης και Μάθησης

AI | LS

Μοντέλα Διάχυσης 2 (*Diffusion Models 2*)

Ηλίας Μήτσουρας

Διάρθρωση της Παρουσίασης

2

□ **Εισαγωγή**

- Πολυτροπική Τεχνητή Νοημοσύνη
- Αναπαράσταση Δεδομένων
- CLIP

□ **Μοντέλα Διάχυσης**

- Διαδικασία Διάχυσης
- Αντίστροφη Διαδικασία Διάχυσης
- Δίκτυο Εκτίμησης Θορύβου
- Σύνθεση Νέων Δειγμάτων
- Επιτάχυνση Διαδικασίας Σύνθεσης Δειγμάτων
- Καθοδήγηση Σύνθεσης από Κειμενική Περιγραφή
- Stable Diffusion
- Diffusion Transformers
- LoRA (Low Rank Adaptation)
- Καθοδήγηση Σύνθεσης από Πολλαπλές Συνθήκες – ControlNet
- Large Language Diffusion Models
- Audio Diffusion Models

Εισαγωγή

3

Πολυτροπική Τεχνητή Νοημοσύνη

- ❑ **Single modal AI:** συστήματα τεχνητής νοημοσύνης τα οποία διαχειρίζονται μόνο έναν τύπο δεδομένων.
- ❑ **Τύποι Δεδομένων (Modalities)**
 - ❑ Κείμενο 
 - ❑ Εικόνα 
 - ❑ Ήχος 
 - ❑ Βίντεο 
- ❑ **Multimodal AI:** συστήματα τεχνητής νοημοσύνης, τα οποία μπορούν να επεξεργάζονται και να κατανοούν **συγχρόνως** πολλαπλούς τύπους δεδομένων.
 - ❑ Συνδυάζουν δύο ή περισσότερους τύπους δεδομένων.

Εισαγωγή


4

Αναπαράσταση Δεδομένων

- Οι υπολογιστές δεν αντιλαμβάνονται τις έννοιες της εικόνας, του ήχου και του κειμένου όπως ο άνθρωπος.


Εικόνες (Images)

- Εικόνα** → συλλογή από pixels.



Ήχος (Audio)

- Ήχος** → συλλογή από χρονικά εξελισσόμενες αριθμητικές τιμές.



Κείμενο (Text)

- Κείμενο** → συλλογή από αναγνωριστικά (tokens), τα οποία αντιστοιχούν σε ένα λεξικό.



"Hello world"

Words: ["Hello", "world"]

Token IDs: [105, 740]

Εισαγωγή

5


Αναπαράσταση Δεδομένων

- ❑ Ένα πολυτροπικό σύστημα τεχνητής νοημοσύνης χρειάζεται μια μορφή **κοινής γλώσσας** για όλους τους τύπους δεδομένων που καλείται να διαχειριστεί.
- ❑ **Πρόβλημα:** οι αριθμητικές αναπαραστάσεις είναι πολύ διαφορετικές για κάθε τύπο δεδομένων.
- ❑ **Λύση:** μετατροπή των αριθμητικών αναπαραστάσεων σε μια κοινή βάση διανυσματικής αναπαράστασης (embeddings).
- ❑ Οι διανυσματικές αυτές αναπαραστάσεις συνδυάζουν τους διαφορετικούς τύπους των δεδομένων σε ένα κοινό χώρο αναπαράστασης.
- ❑ Στο χώρο αυτό, οι αναπαραστάσεις που αντιστοιχούν σε παρόμοιες εισόδους βρίσκονται πιο κοντά, ενώ αναπαραστάσεις που αντιστοιχούν σε αποκλίνουσες εισόδους είναι πιο απομακρυσμένες.

Εισαγωγή

6

Αναπαράσταση Δεδομένων



Εισαγωγή

7

CLIP

- Μοντέλο τεχνητής νοημοσύνης εκπαιδευμένο για την κατανόηση των σχέσεων μεταξύ κειμένων και εικόνων.
- Δοθέντων μιας εικόνας και μιας κειμενικής περιγραφής, το μοντέλο εξετάζει εάν η κειμενική περιγραφή ταιριάζει με την εικόνα.
- **Αρχιτεκτονική**
 - **Text Encoder:** μετατρέπει το κείμενο σε κατάλληλη διανυσματική αναπαράσταση.
 - **Image Encoder:** μετατρέπει την εικόνα σε κατάλληλη διανυσματική αναπαράσταση.
- **Εκπαίδευση:** μεγιστοποίηση της ομοιότητας αναπαραστάσεων που αντιστοιχούν σε σωστά ζεύγη και ελαχιστοποίηση της ομοιότητας αναπαραστάσεων που αντιστοιχούν σε μη σωστά ζεύγη κειμένου-εικόνας
→ **Αντιθετική μάθηση** (contrastive learning)


Εισαγωγή

8

CLIP

□ Διάγραμμα Αρχιτεκτονικής

1. Contrastive pre-training




Εισαγωγή

9

CLIP

■ Χρήση για πρόβλεψη λεζάντας εικόνας

- Η εικόνα δίνεται ως είσοδος στον Image Encoder
→ Παραγωγή διανυσματικής αναπαράστασης εικόνας.
- Πιθανά κείμενα δίνονται ως είσοδοι στον Text Encoder
→ Παραγωγή διανυσματικών αναπαραστάσεων κειμένων.
- Υπολογισμός ομοιότητας ζευγών αναπαραστάσεων εικόνας – κειμένων.
- Επιλογή του ζεύγους με τη μεγαλύτερη ομοιότητα.




Εισαγωγή

10

CLIP

- Χρήση για ανάκτηση εικόνας από κειμενική περιγραφή




Εισαγωγή

11

CLIP

- Χρήση ως σύστημα κωδικοποίησης πληροφορίας
 - Χρήση του Text Encoder για δημιουργία διανυσματικών αναπαραστάσεων κειμένων και χρήση σε άλλο μοντέλο.
 - Διανυσματικές αναπαραστάσεις οι οποίες αποτυπώνουν τη σχέση μεταξύ κειμένου - εικόνων.




Εισαγωγή

12

CLIP

- Χρήση ως σύστημα κωδικοποίησης πληροφορίας (συνέχεια)
 - Χρήση του Image Encoder για δημιουργία διανυσματικών αναπαραστάσεων εικόνων και χρήση σε άλλο μοντέλο.
 - Διανυσματικές αναπαραστάσεις οι οποίες αποτυπώνουν αποτελεσματικά το περιεχόμενο των εικόνων.



Διάρθρωση της Παρουσίασης

13

- Εισαγωγή
 - Πολυτροπική Τεχνητή Νοημοσύνη
 - Αναπαράσταση Δεδομένων
 - CLIP
- **Μοντέλα Διάχυσης**
 - Διαδικασία Διάχυσης
 - Αντίστροφη Διαδικασία Διάχυσης
 - Δίκτυο Εκτίμησης Θορύβου
 - Σύνθεση Νέων Δειγμάτων
 - Επιτάχυνση Διαδικασίας Σύνθεσης Δειγμάτων
 - Καθοδήγηση Σύνθεσης από Κειμενική Περιγραφή
 - Stable Diffusion
 - Diffusion Transformers
 - LoRA (Low Rank Adaptation)
 - Καθοδήγηση Σύνθεσης από Πολλαπλές Συνθήκες – ControlNet
 - Large Language Diffusion Models
 - Audio Diffusion Models


Μοντέλα Διάχυσης

14

Διαδικασία Διάχυσης (Forward Diffusion)

- Διαδοχική προσθήκη θορύβου στα αρχικά δεδομένα μέχρι να καταστραφεί πλήρως η δομή τους $\rightarrow$ θόρυβος.
- Η forward diffusion μοντελοποιείται μέσω μιας Μαρκοβιανής αλυσίδας.
- Δοθέντος ενός δείγματος x_0 από μια κατανομή $x_0 \sim q_0(x)$, κατά το forward diffusion προσθέτουμε διαδοχικά Γκαουσιανό θόρυβο στο δείγμα σε T βήματα, παράγοντας μια ακολουθία ενθόρυβων δειγμάτων $x_1, x_2, \dots, x_T$.
- Χρησιμοποιείται ο πυρήνας μετάβασης $q(x_t | x_{t-1})$, ο οποίος ισούται με:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t | \sqrt{1 - \beta_t} x_{t-1}, \beta_t \mathbf{I})$$




Μοντέλα Διάχυσης

15

Διαδικασία Αντίστροφης Διάχυσης (Reverse Diffusion)

- Αν αντιστρέψουμε τη διαδικασία του forward diffusion και να κάνουμε δειγματοληψία από την κατανομή $q(x_{t-1}|x_t)$, μπορούμε να συνθέσουμε νέα δείγματα, ξεκινώντας από Γκαουσιανό θόρυβο $x_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.



- **Το πρόβλημα:** η κατανομή $q(x_{t-1}|x_t)$ δεν μπορεί **εκτιμηθεί** (intractable), γιατί απαιτεί υπολογισμούς με όλα τα διαθέσιμα δεδομένα.
- **Η λύση:** χρήση νευρωνικού δικτύου $p_\theta(x_{t-1}|x_t)$ για την προσέγγιση των υπό συνθήκη κατανομών $q(x_{t-1}|x_t)$.

Μοντέλα Διάχυσης

16

Δίκτυο Εκτίμησης Θορύβου

□ Συνελικτικά Δίκτυα (Convolutional Neural Networks - CNNs)

- Κλάση δικτύων Βαθιάς Μάθησης.
- Παρόμοια με τα βασικά νευρωνικά δίκτυα.
- Χρησιμοποιούνται κυρίως στον τομέα της Όρασης Υπολογιστών (*Computer Vision*).
- Χρήσιμα για εξαγωγή χαρακτηριστικών από εικόνες.
- Αποτελούνται από 3 είδη στρωμάτων (layers):
 1. **Συνελικτικά Στρώματα (Convolutional Layers):** εφαρμόζουν κυλιόμενα φίλτρα στην εικόνα εισόδου και κατασκευάζουν χάρτες χαρακτηριστικών (*feature maps*).
 2. **Στρώματα pooling:** μειώνουν τη χωρική διάσταση της εισόδου.
 3. **Πλήρως συνδεδεμένα στρώματα (Fully Connected Layers):** διαδοχικά στρώματα νευρώνων.


Μοντέλα Διάχυσης

17

Δίκτυο Εκτίμησης Θορύβου

□ Συνελικτικά Δίκτυα (συνέχεια) - Συνελικτικά Στρώματα

- Κάθε φίλτρο μετακινείται διαδοχικά στην επιφάνεια της εικόνας και εξαάγει μία καθολική τιμή για όσα pixels βλέπει κάθε φορά.
- Οι παράμετροι του φίλτρου μαθαίνονται κατά τη διαδικασία της εκπαίδευσης.




Μοντέλα Διάχυσης

18

Δίκτυο Εκτίμησης Θορύβου

- Συνελικτικά Δίκτυα (συνέχεια) - Συνελικτικά Στρώματα




Μοντέλα Διάχυσης

19

Δίκτυο Εκτίμησης Θορύβου

- Συνελικτικά Δίκτυα (συνέχεια)




Μοντέλα Διάχυσης

20

Δίκτυο Εκτίμησης Θορύβου

□ Συνελικτικά Δίκτυα (συνέχεια)

- Σταδιακή εξαγωγή χαρακτηριστικών των εικόνων εισόδου:
 - Αρχικά στρώματα → χαρακτηριστικά χαμηλού επιπέδου (βασικά δομικά στοιχεία των εικόνων εισόδου, π.χ. γραμμές, ακμές, γωνίες).
 - Μεσαία στρώματα → χαρακτηριστικά μεσαίου επιπέδου (πιο περίπλοκα μοτίβα των εικόνων εισόδου, κύκλου, τετράγωνα, μέρη αντικειμένων).
 - Τελικά στρώματα → χαρακτηριστικά υψηλού-σημασιολογικού επιπέδου (ολόκληρα αντικείμενα και περίπλοκα σημασιολογικά μοτίβα).



Μοντέλα Διάχυσης

21

Δίκτυο Εκτίμησης Θορύβου

□ Δίκτυο U-Net


- Συνελικτικό νευρωνικό δίκτυο με συμμετρική αρχιτεκτονική → διατήρηση χωρικών διαστάσεων εισόδου – εξόδου.
- Χρήσιμο σε εφαρμογές όπου απαιτείται ίδια χωρική διάσταση εισόδου – εξόδου (π.χ. σημασιολογική κατάτμηση – semantic segmentation).
- **Αρχιτεκτονική**
 - **Δίκτυο Κωδικοποιητή (Encoder):** Διαδοχικά επίπεδα με συνελικτικά στρώματα και στώματα pooling.
 - **Bottleneck:** Συνελικτικό στρώμα.
 - **Δίκτυο Αποκωδικοποιητή (Decoder):** Διαδοχικά επίπεδα με συνελικτικά στρώματα διπλασιασμού της χωρικής διάστασης (αντισυμμετρική αρχιτεκτονική με τον encoder).
 - Ανταλλαγή πληροφοριών μεταξύ των στρωμάτων του κωδικοποιητή και του αποκωδικοποιητή.

Μοντέλα Διάχυσης

22

Δίκτυο Εκτίμησης Θορύβου

- Δίκτυο U-Net (συνέχεια)



Μοντέλα Διάχυσης

23

Δίκτυο Εκτίμησης Θορύβου

- Το ενθόρυβο δείγμα x_t στο βήμα t του forward diffusion προκύπτει από το reparametrization trick, ως εξής:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t,$$

- όπου, $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ και $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ τυχαίος θόρυβος.
- Αποδεικνύεται ότι, αρκεί να εκπαιδεύσουμε ένα νευρωνικό δίκτυο αποθορυβοποίησης $\epsilon_\theta(x_t, t)$, ώστε να υπολογίζει το θόρυβο ϵ_t στο τυχόν βήμα t και στη συνέχεια να το χρησιμοποιήσουμε για την παραγωγή νέων δειγμάτων.
- Διαδικασία εκπαίδευσης**
 - Δοθέντος ενός αρχικού δείγματος $x_0 \sim q_0(x)$, επιλέγουμε τυχαία ένα επίπεδο θορύβου $t \sim \text{Uniform}(\{1, \dots, T\})$.
 - Παράγουμε θόρυβο $\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
 - Δημιουργούμε την ενθόρυβη εκδοχή του δείγματος x_t .
 - Λαμβάνουμε την εκτίμηση του θορύβου $\epsilon_\theta(x_t, t)$, μέσω του δικτύου αποθορυβοποίησης.
 - Ανανεώνουμε τα βάρη, ώστε να ελαχιστοποιείται η διαφορά $\|\epsilon_t - \epsilon_\theta(x_t, t)\|^2$.

Μοντέλα Διάχυσης


24

Δίκτυο Εκτίμησης Θορύβου

- Διαδικασία εκπαίδευσης

Algorithm 1 Training

```
1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   Take gradient descent step on
      $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2$ 
6: until converged
```



Μοντέλα Διάχυσης


25

Δίκτυο Εκτίμησης Θορύβου

- Σύνθεση νέων δειγμάτων
 - Αξιοποιώντας το εκπαιδευμένο δίκτυο αποθουροποίησης $\epsilon_{\theta}(x_t, t)$, μπορούμε να ακολουθήσουμε τη reverse diffusion διαδικασία βήμα προς βήμα και να παράξουμε νέα δεδομένα.

Algorithm 2 Sampling

```
1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 
```



Μοντέλα Διάχυσης

26

Denoising Diffusion Implicit Models

- Στα παραδοσιακά μοντέλα διάχυσης η διαδικασία του forward diffusion μπορεί να περιλαμβάνει αρκετές χιλιάδες βήματα (π.χ. $T = 1000$).
- Για να παράξουμε νέα δείγματα, θα πρέπει να ακολουθήσουμε αντίστροφα όλα τα βήματα αυτά → υψηλοί χρόνοι εκτέλεσης.
- **Λύση:** τα Denoising Diffusion Implicit Models, τα οποία επεκτείνουν την ιδέα των παραδοσιακών μοντέλων διάχυσης, και χρησιμοποιούν πολύ μικρότερο αριθμό βημάτων κατά την αντίστροφη διαδικασία διάχυσης.

Εκπαίδευση	Δειγματοληψία
Μεγάλος αριθμός χρονικών βημάτων T (συνήθως μερικές χιλιάδες)	Υποσύνολο των βημάτων που χρησιμοποιούνται κατά την εκπαίδευση

Μοντέλα Διάχυσης

27


Καθοδήγηση Σύνθεσης από Κειμενική Περιγραφή

- **Σκοπός:** παραγωγή ρεαλιστικών εικόνων που ακολουθούν κειμενική περιγραφή, η οποία δίνεται από το χρήστη.
- Υλοποίηση μέσω της μεθόδου **classifier-free guidance** → τροποποίηση της εκτίμησης του θορύβου του δικτύου αποθоруβοποίησης, ώστε να λαμβάνεται υπόψιν και η κειμενική περιγραφή.
- **Διαδικασία Εκπαίδευσης Δικτύου Εκτίμησης Θορύβου με Κειμενική Περιγραφή**
 - ▣ **Δεδομένα Εκπαίδευσης** → Ζεύγη εικόνων – κειμενικών περιγραφών.
 - ▣ Για κάθε ζεύγος εικόνας – κειμενικής περιγραφής:
 1. Προσθήκη θορύβου στην εικόνα.
 2. Είσοδος εικόνας στο δίκτυο αποθоруβοποίησης.
 3. Είσοδος κειμενικής περιγραφής στο δίκτυο αποθоруβοποίησης με πιθανότητα p .
 4. Εκτίμηση θορύβου μέσω του δικτύου αποθоруβοποίησης.
 5. Ανανέωση των παραμέτρων του δικτύου.
 - ▣ Επανάληψη της παραπάνω διαδικασίας N φορές

Μοντέλα Διάχυσης

28

- Διαδικασία Εκπαίδευσης Δικτύου Εκτίμησης Θορύβου με Κειμενική Περιγραφή (συνέχεια)



Μοντέλα Διάχυσης


29

- Με την τυχαία είσοδο της κειμενικής περιγραφής, το δίκτυο μαθαίνει να υπολογίζει το θόρυβο τόσο με, όσο και χωρίς την επίδραση του κειμένου.
- **Σύνθεση Νέων Δειγμάτων με Κειμενική Περιγραφή**
 - ▣ Δοθείσης μιας κειμενικής περιγραφής και ξεκινώντας από τυχαίο θόρυβο:
 1. Είσοδος του ενθόρυβου δείγματος x_T στο δίκτυο **χωρίς** την κειμενική περιγραφή και εκτίμηση του θορύβου $\hat{\epsilon}_\emptyset$.
 2. Εκ νέου είσοδος του τυχαίου θορύβου ϵ στο δίκτυο **με** την κειμενική περιγραφή και εκτίμηση του θορύβου $\hat{\epsilon}_{\text{text}}$.
 3. Υπολογισμός τελικής εκτίμησης θορύβου σύμφωνα με τη σχέση $\hat{\epsilon} = (1 + w) \hat{\epsilon}_{\text{text}} - w \hat{\epsilon}_\emptyset$, όπου w μία παράμετρος η οποία καλείται guidance-strength και καθορίζει το βαθμό επίδρασης της κειμενικής περιγραφής.
 4. Υπολογισμός του δείγματος x_{T-1} βάσει της εκτίμησης του θορύβου $\hat{\epsilon}$.
 5. Επανάληψη των βημάτων 1-4 για T συνολικά βήματα.

Μοντέλα Διάχυσης

30

- Σύνθεση Νέων Δειγμάτων με Κειμενική Περιγραφή (συνέχεια)



Μοντέλα Διάχυσης


31

Stable Diffusion

- Το πιο διαδεδομένο μοντέλο διάχυσης ανοιχτού κώδικα για την παραγωγή εικόνων από κείμενο (text-to-image).
- Λειτουργεί σε έναν λανθάνοντα χώρο αναπαραστάσεων → μείωση διάστασης εικόνων εισόδου.

Αρχιτεκτονική

1. **CLIP Text-Encoder:** παραγωγή αναπαραστάσεων κειμένου βάσει του μοντέλου CLIP.
2. **VAE:** μεταφορά από και προς τον λανθάνοντα χώρο.
3. **Denoising U-Net:** βασικό δίκτυο εκτίμησης θορύβου.




Μοντέλα Διάχυσης

32

Stable Diffusion

CLIP Text-Encoder

- Κωδικοποιητής του μοντέλου CLIP.
- Μετατρέπει το κείμενο εισόδου σε κατάλληλη διανυσματική αναπαράσταση, ώστε να αξιοποιηθεί από το Stable Diffusion.





Μοντέλα Διάχυσης

33

Stable Diffusion

□ VAE

- Μεταφορά από και προς τον λανθάνοντα χώρο → μείωση διαστατικότητας και υπολογιστικού κόστους.
- **Encoder:** μετατροπή εικόνας εισόδου σε μία λανθάνουσα αναπαράσταση.





Μοντέλα Διάχυσης

34

Stable Diffusion

- **VAE (συνέχεια)**
 - ▣ **Decoder:** μετατροπή λανθάνουσας αναπαράστασης σε εικόνα.
 - ▣ Όλη η διαδικασία του forward και του reverse diffusion μεταφέρεται στον λανθάνοντα χώρο.




Μοντέλα Διάχυσης

35

Stable Diffusion

□ Denoising U-Net

- Νευρωνικό Δίκτυο τύπου U-Net.
- Αποτελεί τον βασικό πυρήνα του Stable Diffusion.
- Εκτιμά τον θόρυβο που έχει προστεθεί στην εικόνα εισόδου.
- Περιλαμβάνει διαδοχικά επίπεδα το καθένα από τα οποία αποτελείται από:
 1. Συνελικτικά στρώματα.
 2. Μηχανισμό Attention.



Μοντέλα Διάχυσης

36

Stable Diffusion

□ Μηχανισμός Attention

- Μηχανισμός βάσει του οποίου ένα μοντέλο τεχνητής νοημοσύνης αποφασίζει σε ποια σημεία της εισόδου να εστιάσει την προσοχή του.
- Το δίκτυο εκτίμησης θορύβου του Stable Diffusion χρησιμοποιεί δύο μηχανισμούς προσοχής σε κάθε επιμέρους επίπεδό του.
- **Self-Attention**
 - Κάθε σημείο της εικόνας βλέπει όλα τα άλλα σημεία.
 - Το μοντέλο αντιλαμβάνεται τη συνολική δομή της εικόνας και όχι μόνο τοπικές λεπτομέρειες.

Μοντέλα Διάχυσης


37

Stable Diffusion

□ Μηχανισμός Attention (συνέχεια)

□ Cross-Attention

- Το κείμενο γίνεται ακολουθία από λέξεις / tokens → διανύσματα.
- Κάθε λέξη έχει πρόσβαση σε όλα τα σημεία της εικόνας.
- Μαθαίνει τα σημεία της εικόνας στα οποία ταιριάζει η κάθε λέξη.



Μοντέλα Διάχυσης


38

Stable Diffusion

□ Σύνθεση εικόνων

- Δοθείσης μιας κειμενικής περιγραφής και ξεκινώντας από τυχαίο θόρυβο z_T , ακολουθείται η εξής διαδικασία:

1. Η κειμενική περιγραφή κωδικοποιείται μέσω του CLIP Text-Encoder τ_θ και παράγεται η αντίστοιχη διανυσματική αναπαράσταση.
2. Το ενθόρυβο δείγμα z_T δίνεται ως είσοδος στο δίκτυο εκτίμησης θορύβου (Denoising U-Net).
3. Γίνεται ένα πέρασμα με το κείμενο για την εκτίμηση του θορύβου $\hat{\epsilon}_{\text{text}}$.
4. Γίνεται ένα πέρασμα χωρίς το κείμενο για την εκτίμηση του θορύβου $\hat{\epsilon}_\emptyset$.
5. Υπολογίζεται η τελική εκτίμηση του θορύβου $\hat{\epsilon} = (1 + w) \hat{\epsilon}_{\text{text}} - w \hat{\epsilon}_\emptyset$.
6. Βάσει της εκτίμησης $\hat{\epsilon}$ υπολογίζεται το ενθόρυβο δείγμα z_{T-1} .
7. Επαναλαμβάνονται τα βήματα 2-6 για T βήματα και λαμβάνεται z_1 .
8. Το z διέρχεται μέσα από τον αποκωδικοποιητή του VAE και λαμβάνεται η τελική παραγόμενη εικόνα x .



Μοντέλα Διάχυσης

39

Stable Diffusion

□ Negative Prompt

- Το Stable Diffusion λαμβάνει τις εξής παραμέτρους από το χρήστη για τη σύνθεση μιας εικόνας:
 1. **Prompt:** κειμενική περιγραφή.
 2. **Guidance strength:** βαθμός επίδρασης κειμενικής καθοδήγησης στην τελική εικόνα.
 3. **Negative prompt:** κειμενική περιγραφή προς αποφυγή.
- Μερικές φορές το Stable Diffusion αδυνατεί να αποτυπώσει την κειμενική περιγραφή στην εικόνα, ή εμφανίζει χαρακτηριστικά τα οποία ο χρήστης έχει δηλώσει ρητά να μην εμφανίζονται.
- Με το negative prompt ο χρήστης ορίζει τα χαρακτηριστικά αυτά τα οποία **δεν επιθυμεί** να παρουσιάζονται στην τελική εικόνα που θα παραχθεί.

Μοντέλα Διάχυσης

40

Stable Diffusion

□ Negative Prompt (συνέχεια)


Prompt: "Portrait photo of a man."

Negative prompt: ""




Prompt: "Portrait photo of a man without mustache."

Negative prompt: ""



Prompt: "Portrait photo of a man."

Negative prompt: "mustache"



Μοντέλα Διάχυσης


41

Stable Diffusion


□ Negative Prompt (συνέχεια)

- Σε κάθε βήμα της αντίστροφης διαδικασίας διάχυσης, το negative prompt χρησιμοποιείται ως prompt στο πέρασμα που γίνεται για τον υπολογισμό του θορύβου $\hat{\epsilon}_\theta$.
- Πρακτικά δημιουργείται εσκεμμένα το αντικείμενο προς αποφυγή και στη συνέχεια αφαιρείται από την εικόνα που έχει σχηματιστεί έως το σημείο εκείνο.

Σύνθεση χωρίς negative prompt



Σύνθεση με negative prompt



Μοντέλα Διάχυσης


42

Stable Diffusion

□ Seed

- ▣ Παράμετρος η οποία καθορίζει τον αρχικό θόρυβο, βάσει του οποίου πραγματοποιείται η διαδικασία της αντίστροφης διάχυσης.
- ▣ Είναι ο λόγος για τον οποίο μέσω του ίδιου prompt δημιουργείται διαφορετική εικόνα κάθε φορά.
- ▣ **Σταθερό seed** → ίδιος αρχικός θόρυβος → ίδια εικόνα (εφόσον το prompt είναι το ίδιο).
- ▣ Χρήσιμο για παραγωγή εικόνων με παρόμοια χαρακτηριστικά ή εικονιζόμενα πρόσωπα και αντικείμενα.


portrait of a beautiful woman with blonde hair and blue eyes




portrait of a beautiful woman with blonde hair and blue eyes, smiling



portrait of a beautiful woman with blonde hair and blue eyes, crying



portrait of a beautiful woman with blonde hair and blue eyes, eyes closed



Μοντέλα Διάχυσης

43

Diffusion Transformers

- Τα παραδοσιακά μοντέλα διάχυσης χρησιμοποιούν U-Net ως δίκτυο για την εκτίμηση του θορύβου των εικόνων εισόδου.
- Τα πιο σύγχρονα μοντέλα διάχυσης αντικαθιστούν το U-Net με μία αρχιτεκτονική η οποία ονομάζεται **Diffusion Transformer**.
- **Βασική Ιδέα**
 - ▣ Οι εικόνες εισόδου δεν αντιμετωπίζονται ως ενιαία grid από pixels, αλλά διασπώνται σε επιμέρους τετράγωνα (*patches*).
 - ▣ Γίνεται πολύ καλύτερη εξαγωγή καθολικών χαρακτηριστικών και πιο εύκολη κλιμάκωση.




Μοντέλα Διάχυσης

45

Diffusion Transformers

- Χρήση ως δίκτυο εκτίμησης θορύβου



Μοντέλα Διάχυσης

46

Diffusion Transformers


- Χρήση ως δίκτυο εκτίμησης θορύβου
 - ▣ Εκπαιδεύεται με τον ίδιο τρόπο με αυτό του κλασικού U-Net.
 - ▣ Χρησιμοποιείται με τον ίδιο τρόπο για την παραγωγή νέων εικόνων.
 - ▣ Χρησιμοποιείται στα πιο σύγχρονα μοντέλα διάχυσης, π.χ. Stable Diffusion 3, 3.5.
 - ▣ Παραγωγή καλύτερων και πιο ρεαλιστικών εικόνων.
 - ▣ Καλύτερη συμμόρφωση με την κειμενική περιγραφή.
 - ▣ Πιο γρήγορη εκπαίδευση.

Μοντέλα Διάχυσης

47

LoRA (Low Rank Adaptation)

- Προσαρμογή μεγάλων προεκπαιδευμένων μοντέλων σε ένα μικρό, ορισμένο από το χρήστη σύνολο δεδομένων.
- Διατήρηση της γνώσης του μοντέλου.
- Εισαγωγή ενός μικρού αριθμού παραμέτρων και εκπαίδευση μόνο αυτών.




Μοντέλα Διάχυσης

48

LoRA (Low Rank Adaptation)

□ Παραδείγματα Pixel Art



Barbie



Medieval Fantasy



Μοντέλα Διάχυσης

49


Καθοδήγηση Σύνθεσης από Πολλαπλές Συνθήκες - ControlNet

- Εισαγωγή επιπλέον συνθηκών για την καθοδήγηση της σύνθεσης.



- Text guided Sketch-to-Image Synthesis



- Text guided Depth-to-Image Synthesis



- Text guided Pose-to-Image Synthesis




Μοντέλα Διάχυσης

50

Καθοδήγηση Σύνθεσης από Πολλαπλές Συνθήκες - ControlNet

ControlNet

- Η πιο διαδεδομένη αρχιτεκτονική για την εισαγωγή επιπλέον συνθηκών στη διαδικασία της σύνθεσης.
- Adapter-like δίκτυο, το οποίο λειτουργεί παράλληλα με τη βασική αρχιτεκτονική του Stable Diffusion.
- Επιτρέπει την καθοδήγηση της σύνθεσης βάσει εξωτερικών συνθηκών.
- Κατά την εκπαίδευση το Stable Diffusion παραμένει frozen και ανανεώνονται μόνο τα βάρη του ControlNet.
- Κατά τη σύνθεση των νέων δειγμάτων, οι έξοδοι του ControlNet προστίθενται στις εξόδους του δικτύου εκτίμησης θορύβου του Stable Diffusion.




Μοντέλα Διάχυσης

51

Large Language Diffusion Models

- Μοντέλα διάχυσης για την παραγωγή κειμενικού περιεχομένου.
- Ακολουθούν τη βασική λογική των μοντέλων διάχυσης.
- **Διαδικασία Διάχυσης**
 - ▣ Δοθέντος ενός κειμένου ακολουθείται η εξής διαδικασία:
 1. Γίνεται μετατροπή του κειμένου σε tokens.
 2. Τοποθετούνται μάσκες (θόρυβος) σε τυχαία tokens.
 3. Ένα δίκτυο το οποίο καλείται mask predictor προβλέπει τις τιμές των tokens στα οποία έχουν τοποθετηθεί μάσκες.




Μοντέλα Διάχυσης

52

Large Language Diffusion Models

- Αντίστροφη Διαδικασία Διάχυσης
 - Ξεκινώντας από ένα αριθμό tokens στα οποία έχουν τοποθετηθεί μάσκες, ο Mask predictor αφαιρεί σταδιακά τις μάσκες, έως ότου παραχθεί το τελικό κείμενο.




Μοντέλα Διάχυσης

53

Large Language Diffusion Models

- Πώς το μοντέλο μαθαίνει να παράγει απαντήσεις σε ερωτήσεις του χρήστη (prompts);
 - ▣ Εκπαίδευση του μοντέλου με ζεύγη ερώτησης-απάντησης (prompt-response).
 - ▣ Για κάθε ζεύγος prompt-response, ακολουθείται η εξής διαδικασία:
 1. Γίνεται μετατροπή του ζεύγους σε tokens.
 2. Τοποθετούνται μάσκες (θόρυβος) σε τυχαία tokens, τα οποία αντιστοιχούν **αποκλειστικά και μόνο** στην απάντηση.
 3. Ο mask predictor προβλέπει τις τιμές των tokens στα οποία έχουν τοποθετηθεί μάσκες.
 - ▣ Για την παραγωγή απάντησης βάσει κάποιου prompt, το μοντέλο ξεκινά με ένα αριθμό tokens στα οποία έχουν τοποθετηθεί μάσκες **μόνο** στα tokens της απάντησης και ο mask predictor αφαιρεί σταδιακά τις μάσκες αυτές παράγοντας την τελική απάντηση.



Μοντέλα Διάχυσης

54

Large Language Diffusion Models



- Σύγκριση με τα LLMs (Large Language Models)
 - **GPT:** Μαθαίνει να προβλέπει την επόμενη λέξη της απάντησης, λειτουργώντας αυστηρά γραμμικά (από αριστερά προς τα δεξιά). Δεν έχει τη δυνατότητα να «δει» το τέλος της πρότασης τη στιγμή που γράφει την αρχή της.
 - **LLDM:** Του παρουσιάζουμε ολοκληρωμένη την απάντηση, αλλά «καλύπτουμε» (κρύβουμε με μάσκα) τυχαία τμήματά της. Το μοντέλο μαθαίνει να «συμπληρώνει» τα κομμάτια που λείπουν, έχοντας ταυτόχρονα εικόνα τόσο ολόκληρου του prompt όσο και ολόκληρης της απάντησης.
 - Τα Large Language Diffusion Models είναι πολύ πιο γρήγορα στην παραγωγή κειμενικού περιεχομένου από τα παραδοσιακά LLMs, αλλά υστερούν σε ικανότητες reasoning.
 - Τα Large Language Diffusion Models μπορούν πολύ εύκολα να υλοποιήσουν tasks συμπλήρωσης κειμένου, χωρίς να απαιτείται εκ νέου εκπαίδευση του βασικού μοντέλου.
 - Βρίσκονται ακόμη σε στάδιο ανάπτυξης και διεξοδικής μελέτης (*Gemini Diffusion*).

Μοντέλα Διάχυσης

55

Audio Diffusion Models

- Παραγωγή μουσικής – ηχητικών σημάτων μέσω κειμένου με χρήση μοντέλων διάχυσης.
- Μετατροπή του ηχητικού σήματος σε **φασματογράφημα (spectrogram)** → αναπαράσταση του συχνοτικού περιεχομένου του σήματος στο χρόνο.




Μοντέλα Διάχυσης

56

Audio Diffusion Models

- Εφαρμογή διαδικασίας διάχυσης και αντίστροφης διάχυσης στις εικόνες των φασματογραφημάτων.
- Παραγωγή νέων φασματογραφημάτων και μετατροπή τους σε ηχητικό σήμα – ήχο (vocoder).
- Γνωστά μοντέλα
 - ▣ AudioLDM & Stable Audio → Μοντέλα που λειτουργούν σε λανθάνοντα χώρο αναπαραστάσεων.
 - ▣ Riffusion → Προσαρμοσμένη έκδοχή του Stable Diffusion σε φασματογραφήματα μέσω LoRA.

Τυχαίος θόρυβος



Μοντέλα Διάχυσης

57

Περιορισμοί

- ❑ Υψηλό Υπολογιστικό Κόστος
 - Ανάγκη για πληθώρα υπολογιστικών πόρων → δύσκολη υλοποίηση σε πραγματικό χρόνο
 - Αργή και ιδιαίτερα απαιτητική σε hardware εκπαίδευση
- ❑ Δυσκολία Γενίκευσης σε Άγνωστα Δεδομένα
 - Ανάγκη επανεκπαίδευσης και προσαρμογής
- ❑ Υψηλό Επίπεδο Πολυπλοκότητας
 - Αδυναμία ενσωμάτωσης και χρήσης σε εφαρμογές οι οποίες απαιτούν γνώση του ακριβούς τρόπου λειτουργίας τους.
- ❑ Ελλιπής ικανότητα ερμηνείας των αποτελεσμάτων
 - Προκλήσεις σε εφαρμογές ερμηνεύσιμης τεχνητής νοημοσύνης (Explainable AI)
- ❑ Πολωμένα Αποτελέσματα
 - Οι παραγόμενες εικόνες μπορεί να παρουσιάζουν απόκλιση από τις κειμενικές περιγραφές, λόγω έλλειψης ισορροπίας στα δεδομένα εκπαίδευσης.

"A group of watches showing 5 minutes past 12"



Παραγωγή με χρήση του Stable Diffusion

"A left-handed person writing down on a notebook"




Παραγωγή με χρήση του Stable Diffusion

Μοντέλα Διάχυσης

58

Generative Models Trilemma

- Βασικοί στόχοι ενός παραγωγικού μοντέλου:
 - 1) Παραγωγή υψηλής ποιότητας δειγμάτων,
 - 2) Παραγωγή diverse δειγμάτων και
 - 3) Γρήγορη παραγωγή δειγμάτων με χαμηλό υπολογιστικό κόστος.
- Δεν υπάρχει κάποιο παραγωγικό framework που να ικανοποιεί και τα 3 κριτήρια.
- Variational Autoencoders (VAEs) → χαμηλή ποιότητα παραγόμενων δειγμάτων.
- Generative Adversarial Networks (GANs) → περιορισμένη ποικιλία στα παραγόμενα δείγματα.
- Diffusion Models → υψηλό υπολογιστικό κόστος (μεγάλος αριθμός βημάτων για παραγωγή νέων δειγμάτων).



Διάρθρωση της Παρουσίασης

59

- Εισαγωγή
 - Πολυτροπική Τεχνητή Νοημοσύνη
 - Αναπαράσταση Δεδομένων
 - CLIP
- Μοντέλα Διάχυσης
 - Διαδικασία Διάχυσης
 - Αντίστροφη Διαδικασία Διάχυσης
 - Δίκτυο Εκτίμησης Θορύβου
 - Σύνθεση Νέων Δειγμάτων
 - Επιτάχυνση Διαδικασίας Σύνθεσης Δειγμάτων
 - Καθοδήγηση Σύνθεσης από Κειμενική Περιγραφή
 - Stable Diffusion
 - Diffusion Transformers
 - LoRA (Low Rank Adaptation)
 - Καθοδήγηση Σύνθεσης από Πολλαπλές Συνθήκες – ControlNet
 - Large Language Diffusion Models
 - Audio Diffusion Models



Παραγωγή με χρήση του Stable Diffusion